

Introducción a Big Data con PySpark

Sesión 2: DataFrames y API moderna de PySpark

05/06-Septiembre-2026

Agenda

- Concepto de DataFrames en PySpark
- Características de los DataFrames
- Transformaciones y Acciones



Concepto de DataFrames en PySpark

Un DataFrame en Apache Spark es una colección distribuida de datos organizada en filas y columnas, similar a una tabla en una base de datos relacional.

Spreadsheet on a
single machine



Table or DataFrame partitioned
across servers in a data center



Características de los DataFrames

- **Inmutabilidad:** Una vez creado, un DataFrame no puede ser modificado.
- **Distribución:** Los datos y operaciones se distribuyen entre varios nodos.
- **Tolerancia a fallos:** Reconstruye automáticamente los datos de un DataFrame perdido debido a fallos.
- **Lazy Evaluation:** Las transformaciones no se ejecutan inmediatamente, solo cuando se llama a una acción.
- **Tienen esquema:** nombre y tipo de cada columna.




Transformaciones y Acciones

Transformaciones

- Son operaciones que describen cambios sobre el DataFrame.
- No ejecutan el cómputo en ese momento.
- Regresan un nuevo DataFrame.

Acciones

- Son operaciones que piden un resultado.
 - Disparan la ejecución del plan.
 - Regresan un valor o muestran/traen datos.
- 


Transformaciones y Acciones

Ejemplos típicos

- Transformaciones: select, withColumn, filter/where, join, groupBy
- Acciones: show, count, collect, first

Para recordar la diferencia:

- Si tu línea regresa un DataFrame, casi seguro es transformación.
 - Si regresa un número/lista o imprime resultados, es acción.
- 



¡Manos a la obra con DataFrames!

